

MCDIA500

PROGRAMACIÓN PARA LA

CIENCIA DE DATOS

AVANCE DEL PROYECTO

FASE 1 y 2

Nombre integrante/s:

- Karim Zaid (@karimzaid)
- Daniel Herrera (@dnietoh)
- Jeremmy Díaz (@kirijota98)
- Laura Arenas (@laura-xiphias)

Curso: 202682_1913

Docente: Omar Salinas

Fecha: 17 de septiembre, 2026

GitHub: <https://github.com/laura-xiphias/proyecto-grupo3-mcdi500>

Índice

Introducción	3
Definición de la problemática y objetivos del proyecto	4
Problemática	5
Objetivo general	5
Objetivos específicos	5
Alcance	5
Supuestos	5
Aplicación de herramientas científicas	6
Pandas	6
NumPy	6
Matplotlib y Seaborn	6
Scikit-learn	6
Reproducibilidad técnica	6
Entorno registrado	6
Dependencias declaradas	6
Rutas relativas	7
Semilla aleatoria	7
Evidencia de ejecución completa	7
Preprocesamiento y transformación del dataset	7
Documentación del proceso	7
Vinculación con mapa conceptual	8
Bibliografía	9

Introducción

A pesar de las campañas y medidas de mitigación para disminuir los siniestros de tránsito, se han registrado más de 64.000 siniestros cada año desde el 2020 en Chile (CONASET, 2026). La Comisión Nacional de Seguridad de Tránsito (CONASET) mantiene un registro de siniestros de tránsito a nivel nacional, documentando las condiciones de la vía, el entorno y contexto de lo sucedido a través de Carabineros de Chile como fuente.

Este proyecto utiliza los registros del año 2023, que consta de 5.541 registros individuales, correspondiente a los atropellos ocurridos durante ese año. El conjunto de datos crudos presenta 45 variables que permiten caracterizar el lugar y el momento del evento, así como las condiciones viales, climáticas y de contexto en que ocurrió, además de los resultados en términos de víctimas.

Del total de casos registrados, 407 resultaron con al menos una víctima fatal, correspondiente al 7,35%, evidenciando un desbalance de clases. Este hecho y la cantidad de registros permiten realizar una exploración de los datos que nos permita identificar si los factores de la vía, el entorno y el contexto determinan que un siniestro de tránsito resulte con al menos una víctima fatal.

El objetivo general de este proyecto es identificar los factores de la vía, el entorno y el contexto del siniestro asociados a la probabilidad de que un atropello resulte con víctimas fatales, a partir del registro de atropellos 2023 de CONASET. Este informe documenta el avance correspondiente a las Fases 1 y 2 del proyecto: la definición del problema y del entorno técnico reproducible (Fase 1), y la obtención, exploración y transformación inicial del conjunto de datos (Fase 2); las fases posteriores (F3 y F4) abordarán el modelamiento predictivo y la comunicación de resultados.

Definición de la problemática y objetivos del proyecto

Problemática

Se analizará la severidad de los atropellos ocurridos en Chile en el 2023, entendiendo la severidad como la ocurrencia de al menos una víctima fatal en el siniestro. A través de ello, se busca establecer una asociación entre la severidad y los factores (condiciones de la vía, del entorno y del contexto) presentes en el momento.

Ello nos lleva a establecer la siguiente pregunta: ¿Qué factores —de la vía, del entorno y del contexto del siniestro— determinan la probabilidad de que un atropello resulte con víctimas fatales?

Además, de forma complementaria a la exploración de los datos, evaluar cómo se distribuyen los factores entre los atropellos fatales y no fatales, y si las variables muestran diferencias entre grupos.

El enfoque de asociar la severidad de un siniestro con factores viales, ambientales y contextuales mediante análisis de datos, se enmarca en una línea de investigación consolidada: la revisión sistemática de modelos de predicción de siniestros basados en machine learning identifica precisamente la caracterización de factores determinantes como paso previo indispensable antes de cualquier modelamiento predictivo (Ali et al., 2024).

Objetivo general

Identificar los factores de la vía, del entorno y del contexto del siniestro que se asocian con mayor probabilidad de que un atropello resulte en al menos un fallecido, a partir del registro de atropellos 2023 de CONASET.

Objetivos específicos

- 1- Caracterizar las 45 variables del dataset según el rol analítico, cuantificando la proporción de valores faltantes y columnas redundantes.
- 2- Diagnosticar y tratar los problemas de calidad identificados: faltantes codificados como blancos, ceros con significado de “sin información” y triplicidad de variables geográficas.
- 3- Explorar la asociación entre las variables de vía, entorno y contexto del siniestro, con la ocurrencia de fallecidos, a través de estadística descriptiva y visualizaciones comparativas entre grupos de fatal y no fatal.

Alcance

Este avance abarca la definición del problema y del entorno reproducible (Fase 1) y la obtención, limpieza y transformación inicial del conjunto de datos (Fase 2). Quedan fuera de este alcance: el entrenamiento de cualquier modelo predictivo, la selección de variables para modelamiento y la evaluación de desempeño, que corresponden a la Fase 3.

Supuestos

- La causa del siniestro, al ser asignada por Carabineros, constituye una atribución de responsabilidad y no una medición directa, por lo que cualquier análisis con esa variable hereda el criterio.
- Podrían no estar reflejados todos los fallecidos, si es que el deceso ocurrió posterior a las 48h del siniestro.

- Las variables categóricas no pueden ser verificadas de forma externa, por lo que se consideran correctamente clasificadas por Carabineros.

Aplicación de herramientas científicas

El ecosistema científico se aplicó exclusivamente dentro de funciones modularizadas en F2/src/, nunca en celdas sueltas del notebook, de modo que cada herramienta tiene un propósito declarado en el punto donde se usa:

Pandas

Estructura todo el flujo de datos tabulares. obtencion.cargar_crudo() usa pd.read_csv() para materializar el CSV crudo como DataFrame, sobre una ruta validada previamente con Path.exists(). limpieza.limpiar_datos() aplica drop_duplicates(), dropna() sobre las coordenadas geográficas, y fillna() + str.strip() + str.title() para normalizar las columnas de texto, además de pd.to_datetime() para tipificar la fecha del siniestro. transformacion.generar_nuevas_variables() vuelve a usar pd.to_datetime() sobre la columna Hora para extraer la hora exacta del siniestro como variable numérica limpia (Hora_limpia).

NumPy

Se invoca de forma explícita en transformacion.generar_nuevas_variables(), donde np.where(df['Fallecidos'] > 0, 1, 0) construye Es_Fatal, la variable objetivo-binaria que operacionaliza el fenómeno que el proyecto busca predecir.

Matplotlib y Seaborn

Se usan en exploracion.graficar_contexto_temporal() para visualizar la distribución de siniestros por día de la semana (sns.countplot), apoyando la comprensión exploratoria del dataset ya limpio.

Scikit-learn

Está integrado en transformacion.py (train_test_split, StandardScaler, OneHotEncoder, ColumnTransformer) dentro de la función preprocesar_modelo(), que prepara el dataset para el modelamiento. Su ejecución queda proyectada para la Fase 3, conforme al alcance definido para esta entrega: F2 se detiene en la generación de features (df_features), sin partir aún el conjunto en entrenamiento y prueba.

La correspondencia entre entrada, procesamiento y resultado es verificable directamente en el notebook F2/F2_Preprocesamiento.ipynb: cada celda invoca una única función del módulo correspondiente sobre el DataFrame producido por la celda anterior (df_crudo → df_limpio → df_features), sin pasos intermedios no documentados.

Reproducibilidad técnica

Entorno registrado

El proyecto se desarrolla en Python 3.13.15, dentro de un ambiente virtual (.venv) creado con python -m venv .venv y activado antes de cualquier ejecución, de modo que las dependencias del proyecto quedan aisladas de la instalación global del sistema.

Dependencias declaradas

El archivo `requirements.txt` se genera con `pip freeze` directamente desde el entorno virtual activo, por lo que refleja las versiones efectivamente instaladas —no una lista redactada de memoria— e incluye `pandas`, `numpy`, `matplotlib`, `seaborn` y `scikit-learn`, correspondientes a las herramientas usadas en los notebooks `F1_Definicion` y `F2_Preprocesamiento`.

Rutas relativas

Todas las rutas de datos se referencian de forma relativa al notebook que las usa (por ejemplo, `../F1/data/raw/Atropellos_2023.csv` desde `F2`), en vez de rutas absolutas del computador de origen, permitiendo que el proyecto se ejecute igual en cualquier equipo del grupo que clone el repositorio.

Semilla aleatoria

La única operación no determinística proyectada hasta ahora —el `train/test split` dentro de `transformacion.preprocesar_modelo()`— ya fija `random_state=42`, asegurando que la partición sea reproducible en Fase 3 cuando se ejecute.

Evidencia de ejecución completa

Ambos notebooks (`F1_Definicion` y `F2_Preprocesamiento`) se verificaron con `Kernel → Restart Kernel and Run All Cells`, confirmando que corren de principio a fin sin errores y sin depender de estado previo en memoria, en el equipo de cualquier integrante que tenga el entorno configurado según el README.

Preprocesamiento y transformación del dataset

El perfilado inicial (Fase 1) identificó 5.541 filas sin duplicados exactos ni valores NaN en ninguna columna. Sin embargo, el mismo diagnóstico reveló 7.981 celdas de texto vacías o con solo espacios en blanco, concentradas en seis columnas: `Ruta` (4.966, 89,62%), `Calle_Dos` (1.808, 32,63%), `Calle_Uno` y `Intersecci` (575 cada una, 10,38%), `Condición` (54, 0,97%) y `Ubicación` (3, 0,05%).

Por ello, se descartó eliminar las filas afectadas, porque `Ruta` por sí sola concentra el 89,62% del dataset. Se descartó también imputar por moda o un valor estadístico, porque estas columnas son identificadores de ubicación (nombres de calles y rutas), no variables numéricas ni categóricas con una moda representativa. Además, se optó por declarar explícitamente el vacío con la etiqueta 'Desconocido', preservando la fila y dejando trazable que el dato de ubicación específica no estaba disponible en el registro original.

Respecto a la transformación aplicada, `limpieza.limpiar_datos()` aplica `fillna()` seguido de `.replace('', 'Desconocido')` sobre las seis columnas identificadas, donde el primero cubre eventuales NaN reales, y el segundo cubre los strings vacíos que efectivamente predominan en este dataset, además de tipificar la fecha del siniestro con `pd.to_datetime()`.

Tras aplicar la limpieza, se verificó nuevamente el conteo de celdas vacías en las mismas seis columnas, confirmando 0 en todas ellas, siendo esto una evidencia visible en el notebook de que el tratamiento fue efectivo y completo, no solo declarado.

Documentación del proceso

- 1- **Reutilización de `F1/data/processed/` para el output de `F2`:** Se optó por aprovechar la carpeta ya

existente en F1 (aún vacía) en vez de crear una estructura data/processed propia dentro de F2, evitando duplicar carpetas de datos procesados entre fases consecutivas de un mismo pipeline. Esto mantiene una única ubicación de salida reproducible para el dataset transformado, sin fragmentar la trazabilidad de dónde vive cada versión del dato.

- 2- **Alcance de F2 limitado a la generación de features, sin train/test split:** La función `preprocesar_modelo()` en `transformacion.py` ya está escrita y probada, pero su ejecución se dejó fuera del notebook F2. El motivo es que el split y el modelamiento corresponden a la Fase 3 según el flujo de trabajo definido en la Formativa 1, por lo que ejecutarlo en F2 habría mezclado el alcance de dos fases evaluadas por separado. Como resultado el notebook F2 termina limpiamente en `df_features`, dejando el split como el primer paso reproducible de la siguiente entrega.
- 3- **Corrección de las columnas tratadas en limpieza.limpiar_datos():** La función inicial rellenaba nulos en columnas que, según el diagnóstico real de F1, tenían 0 celdas vacías (Tipo_direc, Direccion, COMUNA1, REGION), dejando sin tratar las seis columnas que sí concentraban las 7.981 celdas en blanco documentadas (Ruta, Calle_Uno, Calle_Dos, Intersecci, Condición, Ubicación). Los "faltantes" de este dataset no son NaN sino strings vacíos, que `fillna()` no captura por sí solo. Se descartó eliminar esas filas, porque Ruta concentra el 89,62% del dataset y su eliminación habría reducido drásticamente una muestra ya desbalanceada (7,35% de casos fatales). Posteriormente, se corrigió la función para tratar las columnas reales, agregando `.replace("", 'Desconocido')` junto al `fillna()`, y se verificó con un conteo posterior que las seis columnas quedan en 0 celdas vacías tras la limpieza.

Vinculación con mapa conceptual

Elemento del mapa	Estado	Evidencia
Problemática y datos	Completado	Sección "Problemática y objetivos" del informe; celda narrativa en F1_Definicion.ipynb
Flujo de trabajo (Definición a Evaluación)	Parcialmente completado	Etapas 1-4 ejecutadas en F2_Preprocesamiento.ipynb; etapas 5-6 (modelamiento, evaluación) proyectadas para Fase 3
Ecosistema de herramientas (Git, GitHub, Jupyter, Python)	Completado	Repositorio proyecto-grupo3-mcdi500; notebooks F1_Definicion.ipynb y F2_Preprocesamiento.ipynb
Versionamiento (commits, ramas, pull request)	Completado	Historial de 20+ commits con prefijos docs/data/feat/fix; ramas por integrante (f2-limpieza, f2-obtencion) fusionadas por pull request
Entorno técnico (data/raw, data/processed, src/, requirements.txt)	Completado	Estructura de carpetas F1/ y F2/ en el repositorio; requirements.txt regenerado con pip freeze
Principios metodológicos (reproducibilidad, trazabilidad, documentación)	Completado	.venv + requirements.txt (reproducibilidad); historial de Git + registro de decisiones del criterio 7 (trazabilidad); comentarios en código y notebooks (documentación)
Train/test split y modelamiento (Análisis y modelamiento)	Proyectado a Fase 3	Función `preprocesar_modelo()` ya escrita en transformacion.py, con `random_state=42` fijado, pero sin ejecutar en este avance
Evaluación y comunicación de resultados	Proyectado a Fase 3	Sin evidencia aún, corresponde a la fase de modelamiento y sus métricas

Bibliografía

Ali, Y., Hussain, F., & Haque, M. M. (2024). Advances, challenges, and future research needs in machine learning-based crash prediction models: A systematic review. **Accident Analysis & Prevention*, 194*, 107378. <https://doi.org/10.1016/j.aap.2023.107378>

Comisión Nacional de Seguridad de Tránsito. (2026). Informe nacional de siniestros de tránsito en Chile 2025. CONASET, Ministerio de Transportes y Telecomunicaciones. <https://www.conaset.cl/wp-content/uploads/2026/08/Informe-Nacional-2025.pdf>

Universidad Andrés Bello. (2026). *Guía de desarrollo — Evaluación Sumativa 1 (Fases 1 y 2): MCDI500* [Material del curso]. Magíster en Ciencia de Datos e Inteligencia Artificial, UNAB.

Universidad Andrés Bello. (2026). *Guía Git y GitHub para Windows: MCDI500* [Material del curso]. Magíster en Ciencia de Datos e Inteligencia Artificial, UNAB.